

Fake Reviews and Opinion Spam Detection using Machine Learning Algorithms

Software Engineering Graduation Project Report

Murat Ay | 2026

ÖZET

Çevrimiçi platformlarda kullanıcı yorumları, tüketicilerin satın alma kararlarını doğrudan etkileyen önemli bilgi kaynaklarıdır. Fakat yanıltıcı sahte yorumların (opinion spam) artması, platformlara duyulan güveni azaltmıştır. Bu çalışmada, sahte ve gerçek yorumların metin tabanlı özellikler kullanılarak otomatik biçimde sınıflandırılması amaçlanmıştır.

- Çalışmada Kaggle platformundan elde edilen 40.432 yorumdan oluşan dengeli bir veri seti kullanılmıştır. Veri setinde 20.216 bilgisayar tarafından üretilmiş sahte yorum (CG) ve 20.216 gerçek kullanıcı yorumu (OR) bulunur. Metinler temizlenip, TF-IDF yöntemiyle sayısal özniteliklere dönüştürülür ve Naive Bayes, Lojistik Regresyon, LinearSVC ve Rastgele Orman algoritmalarıyla sınıflandırılır.
- Test sonuçlarında LinearSVC modeli %91,29 doğruluk ve F1 skoru ile klasik makine öğrenmesi modelleri arasında en başarılı sonucu vermiştir. Bunun yanında, ayrı oluşturulan dış test setinde modelin daha modern ve gerçekçi sahte yorumları yakalamakta zorlandığı görülmüştür. Bu sebeple çalışma yalnızca yüksek iç test başarısını değil, dağılım dışı testlerde ortaya çıkan sınırlılıkları da raporlamaktadır.

Anahtar Kelimeler: Sahte Yorum Tespiti, Makine Öğrenmesi, Doğal Dil İşleme, Opinion Spam, TF-IDF, Destek Vektör Makineleri.

İÇİNDEKİLER

KISALTMALAR LİSTESİ.....	5
BÖLÜM 1: GİRİŞ.....	6
1.1 Problem Tanımı ve Motivasyon.....	6
1.2 Çalışmanın Amacı.....	6
1.3 Çalışmanın Kapsamı ve Sınırlılıklar.....	7
BÖLÜM 2: LİTERATÜR TARAMASI.....	8
2.1 Sahte Yorum Tespitinin Tarihsel Gelişimi.....	8
2.2 Makine Öğrenmesi ve Derin Öğrenme Yaklaşımları.....	8
2.3 Literatür Özet Tablosu.....	8
BÖLÜM 3: METODOLOJİ.....	10
3.1 Veri Seti.....	10
3.2 Veri Ön İşleme.....	11
3.3 Öznitelik Çıkarımı: TF-IDF.....	12
3.4 Kullanılan Algoritmalar.....	13
3.5 Değerlendirme Metrikleri.....	14
3.6 Deneysel Ortam.....	14
BÖLÜM 4: DENEYSEL SONUÇLAR.....	15
4.1 Keşifsel Veri Analizi.....	15
4.2 Model Eğitim Süreci ve Çıktılar.....	16
4.3 Model Performans Sonuçları.....	17
4.4 Karışıklık Matrisleri ve Görsel Karşılaştırma.....	18
4.5 Çapraz Doğrulama Sonuçları.....	19
4.6 Robustluk Analizi ve Dış Test Sonuçları.....	20
4.6.1 Dış Test Setinin Oluşturulması.....	20
4.6.2 Baseline Dış Test Performansı.....	20
4.6.3 Karar Eşiği Optimizasyonu Denemesi.....	21
4.6.4 Veri Artırımı Denemeleri.....	22

4.6.5	Hata Analizi.....	22
4.6.6	Robustluk Analizi Bulguları.....	23
4.6.7	Abstention Yaklaşımı ile Sistem İyileştirmesi.....	23
BÖLÜM 5: TARTIŞMA.....		27
5.1	Araştırma Sorularının Cevaplanması.....	27
5.2	Model Performanslarının Değerlendirilmesi.....	27
5.3	Literatür ve Pratik Karşılaştırma.....	28
5.4	Sınırlılıklar ve Dış Test Bulguları.....	28
BÖLÜM 6: SONUÇ VE GELECEK ÇALIŞMALAR.....		30
6.1	Sonuç.....	30
6.2	Gelecek Çalışmalar.....	30
KAYNAKLAR.....		32

KISALTMALAR LİSTESİ

SVM – Support Vector Machine (Destek Vektör Makineleri)

NB – Naive Bayes (Saf Bayes Sınıflandırıcısı)

LR – Logistic Regression (Lojistik Regresyon)

RF – Random Forest (Rastgele Orman)

NLP – Natural Language Processing (Doğal Dil İşleme)

TF-IDF – Term Frequency-Inverse Document Frequency

ML – Machine Learning (Makine Öğrenmesi)

EDA – Exploratory Data Analysis (Keşifsel Veri Analizi)

CV – Cross-Validation (Çapraz Doğrulama)

CG – Computer Generated (Bilgisayar Üretilmiş Yorum)

OR – Original Review (Orijinal Yorum)

BERT – Bidirectional Encoder Representations from Transformers

LSTM – Long Short-Term Memory

API – Application Programming Interface

OOD – Out-of-Distribution (Dağılım Dışı)

BÖLÜM 1: GİRİŞ

1.1 Problem Tanımı ve Motivasyon

İnternetin yaygınlaşması ve e-ticaretin hızlı büyümesiyle birlikte, tüketiciler ürün ve hizmetlere ilişkin kararlarını büyük ölçüde çevrimiçi yorumlara dayandırmaktadır. Amazon, Yelp, TripAdvisor, Trendyol ve Hepsiburada gibi platformlarda yer alan kullanıcı değerlendirmeleri, tüketicilerin kalite ve güvenilirlik algısını etkileyebilmektedir. Bir ürünün yıldız puanı, yorum sayısı ve içerik kalitesi, kullanıcıların satın alma davranışını doğrudan etkilemektedir (Luca ve Zervas, 2016).

Bu durum, ticari çıkar sağlamak amacıyla oluşturulan sahte yorumların artmasına yol açmıştır. Sahte yorumlar; işletmelerin kendi ürünlerini övmesi (pozitif spam) veya rakiplerini kötülemesi (negatif spam) şeklinde ortaya çıkabilmektedir. Bu tür içerikler, tüketici güvenini zedelemekte ve pazarın işleyişini bozabilmektedir (Jindal ve Liu, 2008). Özellikle yapay zekâ tabanlı metin üretim araçlarının yaygınlaşması, sahte yorumların daha ikna edici hale gelmesine neden olmaktadır.

BrightLocal (2024) tüketici anketine göre, tüketicilerin %75'i yerel işletmeleri değerlendirirken çevrimiçi yorumları okumakta ve satın alma kararları da buna göre şekillenmektedir. Google, yalnızca 2023 yılında 170 milyonun üzerinde politika ihlali içeren yorumu platformundan kaldırmıştır. Bu veriler sorunun boyutunu gösterir.

Geleneksel manuel inceleme yöntemleri, artan veri hacmi ve sahte yorumların giderek daha doğal görünmesi nedeniyle yetersiz kalmaktadır. Ott ve arkadaşları (2011), insan değerlendirmecilerin sahte yorumları tespit etme başarısının şans düzeyine yakın olduğunu göstermiştir. Bu yüzden otomatik sahte yorum tespiti araştırmaları önemli hale gelmiştir.

1.2 Çalışmanın Amacı

Bu çalışmanın temel amacı, makine öğrenmesi algoritmaları kullanarak sahte yorumların otomatik olarak tespit edilmesini sağlamaktır. Çalışma kapsamında aşağıdaki araştırma soruları ele alınmıştır:

S1: Metin tabanlı öznelilikler (TF-IDF) kullanılarak sahte yorumlar ne düzeyde tespit edilebilir?

S2: Farklı makine öğrenmesi algoritmaları (Naive Bayes, Lojistik Regresyon, SVM, Rastgele Orman) arasında performans açısından anlamlı farklılıklar var mıdır?

S3: Hangi algoritma, sahte yorum tespiti için en yüksek doğruluk ve genelleme kapasitesini sunmaktadır?

S4: Eğitilen model, eğitim veri seti dışında hazırlanan dış test yorumlarında nasıl bir performans gösterir?

1.3 Çalışmanın Kapsamı ve Sınırlılıklar

Bu çalışma, yalnızca yorum metinlerine dayalı sahte yorum sınıflandırmasına odaklanmaktadır. Kullanıcı davranışları, hesap bilgileri ve platform etkileşimleri gibi metin dışı veriler kapsama dahil değildir. Modelin modern yapay zekâ üretimi yorumlar karşısındaki sınırlılıkları ise Bölüm 5.4'te ayrıca tartışılmıştır.

BÖLÜM 2: LİTERATÜR TARAMASI

2.1 Sahte Yorum Tespitinin Tarihsel Gelişimi

Sahte yorum tespiti alanındaki ilk akademik çalışmalardan biri, Jindal ve Liu'nun (2008) çalışmasıdır. Bu çalışma, 'opinion spam' kavramını sistematik olarak tanımlayan ilk akademik yayındır. Araştırmacılar, Amazon'dan toplanan 2,14 milyon yorum üzerinde lojistik regresyon kullanarak kopya ve yanıltıcı yorumları tespit etmeye odaklanmışlardır.

Ott ve arkadaşları (2011), sahte yorum tespitinde sık kullanılan etiketli veri setini oluşturmuştur. Amazon Mechanical Turk aracılığıyla 400 sahte otel yorumu ürettirmişler ve bunları 400 gerçek yorum ile birleştirmişlerdir. Çalışmalarında SVM ve Naive Bayes modelleriyle yaklaşık %89,8 doğruluk oranı elde etmişlerdir. Önemli bir bulgu olarak, insan değerlendirmecilerin sahte yorumları tespit etme başarısının şans düzeyine yakın olduğunu göstermişlerdir.

Feng ve arkadaşları (2012) sözdizimsel özelliklerin aldatma tespitindeki etkinliğini incelemiş, Mukherjee ve arkadaşları (2012, 2013) ise sahte yorum yazan grupların tespiti ve davranışsal ayak izleri üzerine çalışmalar yapmıştır. Bu çalışmalar, sahte yorum tespitinde metin-dışı özelliklerin de değerli olduğunu göstermiştir.

2.2 Makine Öğrenmesi ve Derin Öğrenme Yaklaşımları

Geleneksel makine öğrenmesi algoritmaları, sahte yorum tespitinde yaygın olarak kullanılmaktadır. Bu yaklaşımlarda genellikle TF-IDF veya Bag-of-Words ile öznitelik çıkarımı yapılmakta ve ardından sınıflandırma algoritmaları uygulanmaktadır.

Mohawesh ve arkadaşları (2021), kavram kayması (concept drift) olgusunun sahte yorum tespiti modellerinin uzun vadeli başarısı üzerindeki olumsuz etkisini istatistiksel olarak kanıtlamıştır. Bu bulgu, sahte yorum tespiti modellerinin zamana ve veri kaynağına duyarlı olduğunu gösterir.

2.3 Literatür Özet Tablosu


Çalışma	Yıl	Yöntem	Veri Seti	Boyut	Doğruluk
Jindal ve Liu	2008	Lojistik Regresyon	Amazon	2,14M	-

Ott vd.	2011	SVM, NB	Yelp (MTurk)	1.600	%89,8
Mukherjee vd.	2013	Davranışsal	Yelp	Geniş	-
Hajek vd.	2020	DNN + Duygu	Yelp/TripAdvisor	Çeşitli	%89~
Fornaciari vd.	2021	BERT (BERTective)	Çeşitli	Çeşitli	%92~
Bu Çalışma	2026	TF-IDF + SVM (LinearSVC)	Kaggle Fake Reviews Dataset	40.432	%91,29

Tablo 1: Literatürdeki temel çalışmalar ve bu çalışmanın karşılaştırması

BÖLÜM 3: METODOLOJİ

Bu çalışma, sahte yorum tespitini ikili sınıflandırma (binary classification) problemi olarak ele almaktadır. Yorumlar 'Sahte' (CG – Computer Generated) veya 'Gerçek' (OR – Original Review) olarak etiketlenmektedir. Şekil 1'de sistemin genel mimarisi ve veri akışı sunulmaktadır.



Şekil 1: Sistem mimarisi ve veri akışı. Mavi: veri hazırlama; yeşil: model geliştirme; turuncu: uygulama katmanı.

3.1 Veri Seti

Çalışmada Kaggle platformundan elde edilen 'Fake Reviews Dataset' kullanılmıştır (Salminen vd., 2022). Bu veri seti, 20.216 sahte (bilgisayar üretilmiş) ve 20.216 gerçek (insan tarafından yazılmış) olmak üzere toplam 40.432 ürün yorumundan oluşmaktadır. Veri setinin dengeli dağılıma sahip olması (%50 sahte, %50 gerçek), sınıflandırma modellerinin eğitimi için iyi bir ortam sağlamaktadır. Veri setinin temel özellikleri Tablo 2'de özetlenmektedir.

Özellik	Değer
---------	-------

Toplam Yorum Sayısı	40.432
Sahte Yorum (CG)	20.216 (%50)
Gerçek Yorum (OR)	20.216 (%50)
Sütunlar	category, rating, label, text_
Eksik Veri	0 (hiç eksik değer yok)
Dil	İngilizce
Kategoriler	Home & Kitchen, Electronics, Clothing vb.

Tablo 2: Veri seti özellikleri

Tablo 3'te veri setinden alınmış örnek yorumlar sunulmaktadır. Bu örnekler, sahte ve gerçek yorumlar arasındaki üslup farkını gösterir.

Etiket	Kategori	Örnek Yorum (özet)
OR	Kindle Store	This was a good book with good characters....well written....would read more by this author. It was a little predictable, but still enjoyable.
OR	Pet Supplies	Don't bother buying this. I purchased it to locate where my cat had sprayed so I could treat the correct places and this light did nothing!
OR	Sports	A nice scope mount. Blue loctite on the threaded connections and you won't be disappointed.
OR	Kindle Store	I didn't buy this to lose weight, but to get healthy. Not hard to follow and ingredients aren't hard to get.
CG	Kindle Store	Online book purchase enjoy being able to read the series in one sitting. The author has done a great job.
CG	Toys	These were too cheap for what they are. Not worth it. My son loves this! Great quality and great price!
CG	Clothing	I'm not very hard on the ankle, but the ankle is a little tighter than I expected.
CG	Kindle Store	An OK read but I would have liked to see more of the main characters.

Tablo 3: Veri setinden örnek sahte (CG) ve gerçek (OR) yorumlar

3.2 Veri Ön İşleme

Ham metin verileri doğrudan makine öğrenmesi modellerine girilebilecek formatta değildir. Bundan dolayı, metin verileri üzerinde bir dizi Doğal Dil İşleme ön işleme adımı uygulanmıştır. Buradaki amaç metnin içerdiği gürültüyü azaltmak ve modelin öğrenme kapasitesini artırmaktır (Manning vd., 2008). Uygulanan adımlar sırasıyla şunlardır:

- **Küçük harfe dönüştürme:** Tüm karakterler küçük harfe çevrilir; 'Great' ve 'great' aynı kelime olarak değerlendirilir.
- **URL, HTML ve sayı temizliği:** Düzenli ifadeler (regex) ile URL'ler, HTML etiketleri ve sayısal değerler kaldırılır.
- **Noktalama kaldırma:** Python string kütüphanesi ile noktalama işaretleri çıkarılır.
- **Stop-word kaldırma:** 'the', 'is', 'at', 'and' gibi anlamsal düşük öneme sahip kelimeler NLTK kütüphanesi (Bird vd., 2009) listesi ile filtrelenir.
- **Lemmatizasyon:** WordNet Lemmatizer ile kelimeler sözlük formuna indirgenir (örn: 'running' → 'run').

Ön işleme sonrasında 1 adet boş yorum tespit edilerek veri setinden çıkarılmış; temizlenmiş veri seti 40.431 yorumdan oluşmaktadır.

3.3 Öznitelik Çıkarımı: TF-IDF

Metinlerin sayısallaştırılması için TF-IDF (Term Frequency – Inverse Document Frequency) yöntemi kullanılmıştır. TF-IDF, bir terimin hem yerel (doküman içindeki) hem de küresel (tüm dokümanlardaki) önemini dikkate alan istatistiksel bir ölçüttür (Salton ve Buckley, 1988). TF-IDF değeri aşağıdaki formülle hesaplanır: $TF\text{-}IDF(t,d) = TF(t,d) \times IDF(t)$. Burada $TF(t,d)$, t teriminin d dokümanındaki sıklığı; $IDF(t)$ ise $\log(N/df(t))$ olup, N toplam doküman sayısı, $df(t)$ ise t terimini içeren doküman sayısıdır.

Çalışmada kullanılan scikit-learn TF-IDF vektörizasyon parametreleri Tablo 4'te özetlenmektedir.

Parametre	Değer ve Açıklama
max_features	20.000 (en fazla 20.000 kelime)
ngram_range	(1, 2) – unigram ve bigram
max_df	0,95 – dokümanların %95'inden fazlasında geçenleri çıkar
min_df	2 – en az 2 dokümanda geçen kelimeleri al
sublinear_tf	True – logaritmik TF ölçeklemesi

Tablo 4: TF-IDF vektörizasyon parametreleri

3.4 Kullanılan Algoritmalar

Çalışmada dört farklı makine öğrenmesi algoritması karşılaştırmalı olarak değerlendirilmiştir. Tüm algoritmalar scikit-learn 1.5 kütüphanesi ile uygulanmıştır.

Naive Bayes (Multinomial). Bayes teoremine dayanan olasılıksal bir sınıflandırıcıdır. 'Naive' (saf) olarak adlandırılır çünkü özniteliklerin birbirinden bağımsız olduğunu varsayar. Multinomial varyantı metin sınıflandırmada özellikle etkilidir; kelime frekanslarını doğal olarak modeller (McCallum ve Nigam, 1998). Hesaplama maliyeti düşüktür ve baseline (temel karşılaştırma) modeli olarak kullanılmıştır. $\alpha=0,5$ (Laplace düzeltmesi) parametresi uygulanmıştır.

Lojistik Regresyon. Doğrusal bir sınıflandırıcı olup sigmoid fonksiyonu aracılığıyla olasılık çıktısı üretir. Yüksek boyutlu metin verilerinde etkili performans gösterir ve yorumlanabilirliği yüksektir. $\text{max_iter}=5000$, $\text{solver}='liblinear'$, $\text{class_weight}='balanced'$ ve $C=1,0$ parametreleri kullanılmıştır.

Destek Vektör Makineleri (LinearSVC). Vapnik (1995) tarafından geliştirilen ve iki sınıf arasında en geniş marja sahip hiper-düzlemi bulmaya çalışan güçlü bir sınıflandırıcıdır. Joachims (1998) SVM'nin metin sınıflandırma problemlerinde özellikle etkili olduğunu göstermiştir; bunun temel nedeni TF-IDF ile oluşturulan yüksek boyutlu öznitelik uzayında SVM'nin optimal ayırıcıyı etkili bir şekilde bulabilmesidir. LinearSVC, doğrusal çekirdek kullanan ve büyük veri setleri için optimize edilmiş bir SVM implementasyonudur. $\text{max_iter}=5000$, $\text{class_weight}='balanced'$ ve $C=1,0$ parametreleri kullanılmıştır.

Rastgele Orman (Random Forest). Breiman (2001) tarafından önerilen, birden fazla karar ağacının çoğunluk oyuyla sınıflandırma yapan topluluk yöntemidir. Aşırı öğrenmeye karşı dirençlidir ancak seyrek TF-IDF matrislerinde diğer algoritmalarından düşük performans göstermesi beklenmektedir. $\text{n_estimators}=200$, $\text{class_weight}='balanced'$ ve $\text{n_jobs}=-1$ parametreleri ile çalıştırılmıştır.

3.5 Değerlendirme Metrikleri

Veri seti %80 eğitim (32.344 yorum) ve %20 test (8.087 yorum) olarak stratifiye örnekleme ile bölünmüştür (Kohavi, 1995). Stratifiye örnekleme, her iki sette de aynı oranda sahte ve gerçek yorum bulunmasını sağlamaktadır. TF-IDF vektörizasyonu yalnızca eğitim seti üzerinde öğrenilmiş (fit) ve her iki sete uygulanmıştır (transform); bu yaklaşım test setinden eğitim setine bilgi sızıntısı oluşmasını önlemektedir. Sonuç olarak $32.344 \times$

20.000 boyutunda bir eğitim matrisi ve 8.087×20.000 boyutunda bir test matrisi elde edilmiştir.

Modellerin performansı beş temel metrikle değerlendirilmiştir. Doğruluk (accuracy), doğru sınıflandırılan örneklerin toplam örneklere oranıdır ve dengeli veri setlerinde güvenilir bir göstergedir. Kesinlik (precision), sahte olarak tahmin edilen yorumlar arasında gerçekten sahte olanların oranını; duyarlılık (recall) ise gerçekte sahte olan yorumlar arasında doğru tahmin edilenlerin oranını ifade eder. F1 skoru, kesinlik ve duyarlılığın harmonik ortalamasıdır. Son olarak 5-katlı çapraz doğrulama, eğitim verisinin 5 parçaya bölünmesi ve her seferinde farklı bir parçanın test için kullanılmasıyla modelin genelleme kapasitesinin değerlendirilmesidir (Kohavi, 1995).

3.6 DeneySEL Ortam

Deneyler Google Colab ortamında ve yerel makinede tekrarlanarak gerçekleştirilmiştir. Programlama dili olarak Python kullanılmıştır. Temel kütüphaneler arasında pandas, scikit-learn, nltk, matplotlib, seaborn, joblib ve Streamlit bulunmaktadır. Model çıktıları yerel arayüzde kullanılmak üzere .pkl ve .json dosyaları halinde kaydedilmiştir.

Kullanılan Araçlar ve Programlar


Araç / Program	Kullanım Amacı
Python 3.11.9	Veri işleme, model eğitimi, test scriptleri ve model kaydetme işlemleri
Google Colab	Transformer/DistilBERT denemeleri ve GPU destekli eğitim çalışmaları
Visual Studio Code	Kod geliştirme ve proje dosyalarının düzenlenmesi

pandas, NumPy	CSV veri okuma, temizleme, birleştirme ve tablo işlemleri
scikit-learn	TF-IDF, NB, LR, LinearSVC, RF ve metrik hesaplamaları
Streamlit	Modelin kullanıcı arayüzü üzerinden test edilmesi
Matplotlib / Seaborn	Deney çıktılarının ve grafiklerin hazırlanması

BÖLÜM 4: DENEYSEL SONUÇLAR

4.1 Keşifsel Veri Analizi

Model eğitimi öncesinde veri seti üzerinde keşifsel veri analizi (EDA) gerçekleştirilmiştir. Sınıf dağılımı incelendiğinde, veri setinin tamamen dengeli olduğu doğrulanmıştır: 20.216 sahte yorum (CG) ve 20.216 gerçek yorum (OR). Yorum uzunluğu analizinde, sahte yorumların ortalama kelime sayısı gerçek yorumlardan bariz biçimde daha kısadır; bu durum metin uzunluğunun potansiyel bir ayırt edici öznelik olduğunu gösterir.




```
Terminal - fake_review_detector_4.py

$ python fake_review_detector_4.py

[INFO] Veri yüklendi: 40432 yorum
[INFO] Sınıf dağılımı: CG=20216 OR=20216
[INFO] Ön işleme tamamlandı: 40431 yorum
[INFO] TF-IDF vektörizasyon: 32344 x 20000 matris

[INFO] Eğitim başladı...

===== Naive Bayes =====
Accuracy: 0.8908 Precision: 0.8910
Recall: 0.8908 F1 Score: 0.8908
CV (5-fold): 0.8884 +/- 0.0048

===== Logistic Regression =====
Accuracy: 0.9029 Precision: 0.9029
Recall: 0.9029 F1 Score: 0.9029
CV (5-fold): 0.8974 +/- 0.0033

===== SVM (LinearSVC) =====
Accuracy: 0.9129 Precision: 0.9129
Recall: 0.9129 F1 Score: 0.9129
CV (5-fold): 0.9085 +/- 0.0016 <-- EN İYİ MODEL

===== Random Forest =====
Accuracy: 0.8702 Precision: 0.8704
Recall: 0.8702 F1 Score: 0.8701
CV (5-fold): 0.8620 +/- 0.0062

[INFO] Toplam süre: 312 saniye
[INFO] Görselleştirmeler kaydedildi: results/
[INFO] Model exportlandı: models/review_model.pkl
```

Şekil 4: Model eğitim sürecinin terminal çıktısı (örnek görüntü)

4.3 Model Performans Sonuçları

Tüm modellerin test seti performansı Tablo 5'te özetlenmektedir.

Model	Accuracy	Precision	Recall	F1 Score	CV Ort.	CV Std
Naive Bayes	0,8911	0,8912	0,8911	0,8910	0,8882	±0,0048
Logistic Regression	0,9021	0,9021	0,9021	0,9021	0,8975	±0,0032
SVM (LinearSVC)	0,9129	0,9129	0,9129	0,9129	0,9077	±0,0016
Random Forest	0,8695	0,8696	0,8695	0,8695	0,8610	±0,0044

Tablo 5: Tüm modellerin performans metrikleri karşılaştırması. En iyi sonuçlar vurgulanmıştır.


Tablo 5'te görüldüğü gibi SVM (LinearSVC) %91,29 doğruluk ile en yüksek performansı, Rastgele Orman %86,95 ile en düşük performansı sergilemiştir. SVM aynı zamanda en düşük CV standart sapması (±0,0016) ile en tutarlı sonucu vermiştir. SVM modeli için detaylı sınıflandırma raporu Tablo 6'da sunulmaktadır.

Sınıf	Precision	Recall	F1 Score	Destek
REAL / OR	0,91	0,91	0,91	4044
FAKE / CG	0,91	0,92	0,91	4043
Accuracy	-	-	0,9129	8087

Tablo 6: SVM modeli detaylı sınıflandırma raporu

4.4 Karışıklık Matrisleri ve Görsel Karşılaştırma

Karışıklık matrisleri (Şekil 5), SVM modelinin her iki sınıfta da neredeyse simetrik hata dağılımına sahip olduğunu göstermektedir. Yanlış sınıflandırma oranları gerçek ve sahte yorumlar arasında dengeli kalmış; bu durum modelin sınıflar arasında taraflı bir kayma sergilemediğini gösterir.




Şekil 5: Dört modelin karışıklık matrisleri



Şekil 6: Dört modelin accuracy, precision, recall ve F1 score metriklerinin görsel karşılaştırması

4.5 Çapraz Doğrulama Sonuçları

5-katlı çapraz doğrulama sonuçları (Şekil 7), tüm modellerin test performansına yakın değerler ürettiğini ve aşırı öğrenmenin gözlenmediğini göstermektedir.



Şekil 7: 5-katlı çapraz doğrulama sonuçları. Hata çubukları standart sapmayı göstermektedir.

4.6 Robustluk Analizi ve Dış Test Sonuçları

Önceki bölümlerde sunulan deneyler, modelin Kaggle Fake Reviews Dataset üzerindeki yüksek başarısını gösterir. Ancak makine öğrenmesi literatüründe önemli bir konu olarak öne çıkan dağılım kayması (distribution shift) ve jeneratör kayması (generator shift) problemleri, modelin eğitim verisi dışındaki örnekler üzerinde de değerlendirilmesini gerektirmektedir (Mohawesh vd., 2021). Bu bölümde, modelin gerçek dünya senaryolarındaki davranışını incelemek amacıyla yapılan dış test ve robustluk deneyleri sunulmaktadır.

4.6.1 Dış Test Setinin Oluşturulması

Modelin eğitim veri setine olan bağımlılığını ölçmek için, Kaggle veri setinden bağımsız 100 örnekli bir dış test seti oluşturulmuştur. Bu set 50 gerçek (OR) ve 50 gerçekçi sahte (CG) yorumdan oluşmaktadır. Bu deneyin amacı, modelin yalnızca Kaggle test bölümü üzerindeki başarısını değil, eğitim dağılımı dışındaki yorumlara karşı genelleme kabiliyetini de değerlendirmektir.

Bu yaklaşım, Salminen ve arkadaşlarının (2022) orijinal Kaggle veri setinin üretildiği GPT-2 mimarisi ile günümüzdeki GPT-4 ve sonrası dil modelleri arasındaki üretim kalitesi farkının modele etkisini gözlemlemeyi hedeflemektedir. RAID benchmark çalışmasında Dugan vd. (2024), GPT-2 çıktıları üzerinde eğitilmiş RoBERTa-GPT2 tabanlı detektörün Reviews alanındaki doğruluğunun GPT-2 üretimlerinde %97,6 iken GPT-4 üretimlerinde %38,7'ye düştüğü raporlanmıştır.

4.6.2 Baseline Dış Test Performansı

Eğitilen dört modelin dış test seti üzerindeki başarısı Tablo 7'de sunulmaktadır. Sonuçlar, modelin gerçek yorumları neredeyse hatasız tespit ettiğini ancak modern sahte yorumları yakalama oranının oldukça düşük kaldığını göstermektedir.

Model / Deneme	Sahte (CG) Yakalama	Gerçek (OR) Doğru	Yorum
SVM (LinearSVC) final model	2/50	50/50	Gerçek yorumları doğru ayırır; gerçekçi sahte yorumlarda genelleme

			sınırlıdır.
Eşik değeri denemeleri	19/50	25/50	Sahte yakalama artsa da gerçek yorum başarısı ciddi biçimde azalmıştır.
Hedefli veri artırma denemeleri	5/50	50/50	Küçük artış sağlamış, ancak temel genelleme problemini çözmemiştir.
Naive Bayes	0/50	50/50	Sahte sınıfta tamamen başarısız
Rastgele Orman	2/50	50/50	Topluluk yöntemi yeterli değil

Tablo 7: Modellerin dış test seti üzerindeki performansı (100 örnekli)

Bu sonuç, modelin Kaggle veri setinde başarılı olduğunu ancak modern sahte yorumlarda zayıf kaldığını gösterir. Naive Bayes modelinin sahte sınıfta tamamen başarısız olması (0/50), basit olasılıksal modellerin dağılım kayması durumunda hassasiyetinin belirgin biçimde düştüğünü gösterir.

4.6.3 Karar Eşiği Optimizasyonu Denemesi

Düşük sahte yakalama oranını iyileştirmek için ilk olarak SVM modelinin karar eşiği (decision threshold) düşürülmüştür. Modelin standart eşik değeri 0,0'dır. Bu eşik değeri daha düşüğe ayarlandığında, sınıflandırma sınırını sahte sınıfına doğru kaydırmaktadır. Bu denemenin sonuçları Tablo 8'de gösterilmektedir.

Eşik Değeri	Sahte (CG)	Gerçek (OR)	Genel Sonuç
0,00	2/50	50/50	Final SVM modelinde varsayılan karar eşiği gerçek yorumları korudu, ancak CG yakalama zayıf kaldı.
-0,50	10/50	42/50	CG yakalama artsa da gerçek yorum hataları yükseldi.
-0,75	14/50	36/50	Denge bozuluyor
-1,00	19/50	25/50	Agresif eşik ayarı toplam performansı bozdu.

Tablo 8: Karar eşiği değişimine bağlı sahte ve gerçek yorum sınıflandırma performansı

Sonuçlar, eşik değerini düşürerek sahte yakalama oranı %4'den %38'e yükseltilebilse de bu artışın gerçek yorumların doğru sınıflandırılması pahasına gerçekleştiğini gösterir. Bu yüzden karar eşiği optimizasyonu, problemin tek çözümü olarak değerlendirilmemiştir.

4.6.4 Veri Artırımı Denemeleri

İkinci yaklaşım olarak, eğitim veri setine modern dil modeli üretimi sahte yorumlar eklenerek veri artırımı (data augmentation) denemeleri yapılmıştır. Bu yöntem, literatürde dağılım kayması problemine karşı en sık önerilen çözümlerden biridir (Balkus ve Yan, 2024; Liu ve Poesio, 2024).

Deney	İç Test Accuracy	İç Test F1	Dış Test CG Yakalama	Dış Test OR Doğru
Temel SVM modeli	0,9129	0,9129	2/50	50/50
+200 CG, +200 OR (hard aug.)	0,9153	0,9153	4/50	49/50
+Ott Deceptive Opinion Corpus	0,9072	0,9072	Düşük	Düşük

Tablo 9: Farklı veri artırımı yaklaşımlarının iç ve dış test performansına etkisi

Tablo 9'da görüldüğü üzere, sentetik veri artırımı iç test performansını koruyor veya hafifçe artırırken, dış test üzerindeki sahte yakalama oranını anlamlı şekilde iyileştirememiştir. Hatta farklı bir veri seti olan Ott Deceptive Opinion Corpus eklendiğinde, dağılım farklılığı nedeniyle iç test başarısı da düşmüştür.

4.6.5 Hata Analizi

Dış test setindeki yanlış sınıflandırılan örnekler incelendiğinde, kaçırılan sahte yorumların çoğunun doğal ve dengeli bir anlatıma sahip olduğu görülmüştür. Bu örneklerde ürün kullanımı, küçük kusurlar, zaman bilgisi ve kişisel deneyim gibi gerçek yorumlarda sık görülen unsurlar bilinçli biçimde kullanılmıştır. Bu durum, modelin daha çok veri setindeki yüzeysel dil kalıplarını öğrendiğini ve daha gerçekçi sahte yorumlarda genelleme yapmakta zorlandığını göstermektedir.

4.6.6 Robustluk Analizi Bulguları

Robustluk analizi, klasik makine öğrenmesi yöntemlerinin dağılım dışı sahte yorum tespitinde sınırlı kaldığını göstermiştir. Karar eşiği optimizasyonu ve veri artırımı denemeleri bazı örneklerde küçük iyileşmeler sağlamış, ancak dış test başarısını istenen seviyeye çıkarmamıştır. Bu sonuç, iç test başarısının tek başına yeterli olmadığını ve modelin farklı kaynaklardan gelen örneklerle ayrıca değerlendirilmesi gerektiğini gösterir.

4.6.7 Abstention Yaklaşımı ile Sistem İyileştirmesi

Önceki alt bölümlerde sunulan bulgular, modelin özellikle modern dil modeli üretimi yorumlarda karar sınırına yakın tahminler ürettiğini göstermektedir. Bu eksikliğin pratik bir çözümü olarak, modelin düşük güvenli kararlar için tahminden kaçınmasını (abstention) sağlayan bir mekanizma sistem mimarisine entegre edilmiştir. Bu yaklaşım, akademik literatürde seçici sınıflandırma (selective classification) olarak bilinen alan ile uyumludur.

Uygulanan abstention mekanizmasında iki kriter birlikte değerlendirilmektedir: (1) Modelin sigmoid fonksiyonu aracılığıyla $[0, 1]$ aralığına dönüştürülmüş olasılık-benzeri güven skoru 0,55 değerinin altında ise tahmin 'kararsız' olarak işaretlenir; (2) SVM karar fonksiyonunun mutlak değeri 0,20'den küçük ise — yani örnek hiper-düzleme çok yakın ise — tahmin yine 'kararsız' olarak işaretlenir. LinearSVC predict_proba'yı doğrudan desteklemediği için ham karar skoru sigmoid ile dönüştürülmüştür; bu skor kalibre edilmiş bir olasılık olmamakla birlikte, eşik tabanlı karar mekanizması için yeterli ayırt edicilik sağlamaktadır. Bu iki kriterin birlikte uygulanması, modelin hem olasılık tahmininde hem de geometrik karar sınırı analizinde belirsizlik gösterdiği durumları yakalamayı amaçlamaktadır.

Geliştirilen Streamlit arayüzünde bu mekanizma kullanıcıya sade biçimde sunulmuştur. Model güven skoru yeterli olduğunda sonuç 'GERÇEK YORUM' veya 'SAHTE YORUM' olarak gösterilir. Güven skoru belirlenen aralığın altında kaldığında ise sistem kesin bir karar vermek yerine 'KARARSIZ' sonucunu üretir. Böylece düşük güvenli tahminlerin kullanıcı tarafından kesin sonuç gibi yorumlanması önlenir.

The screenshot displays the 'Fake Review Detection System' interface. At the top, the title 'Fake Review Detection System' is shown in a large, bold font. Below it, a subtitle reads 'AI-based review authenticity analysis interface'. A blue box contains a note: 'This model was trained on an English fake review dataset. For reliable results, enter English product reviews.' Below this, a text input field is labeled 'Enter a product review:'. The input field contains a sample review about a dog toy. Below the input field are two buttons: 'Analyze' (in blue) and 'Clear' (in grey). Below the buttons, the 'Result' section is displayed. It features a green box with a checkmark icon and the text 'This review is classified as REAL.' Below this, the 'Prediction' is shown as 'REAL' and the 'Confidence Score' is '68.4%'. A horizontal progress bar is shown below the confidence score, with a blue segment representing the 68.4% confidence level.

Fake Review Detection System

AI-based review authenticity analysis interface

This model was trained on an English fake review dataset. For reliable results, enter English product reviews.

Enter a product review:

This ball and squeaker has outlasted all the other squeaky dog toys, including the Hippo Kong and Kyjen Platypus Plush Squeaky Eggs. The Kyjen Invincibles Plush Snake Stuffingless Dog Toy is still squeaking and in pretty good shape. The pup detached some trim but couldn't figure out how to tear it up. She shredded her Kong Ballistic Ring Dog Toy in no time, sadly.

Analyze Clear

Result

✓ This review is classified as REAL.

Prediction Confidence Score

REAL 68.4%

Şekil 8: Streamlit arayüzünde 'GERÇEK YORUM' sonucu (güven %68,4)

Fake Review Detection System

AI-based review authenticity analysis interface

This model was trained on an English fake review dataset. For reliable results, enter English product reviews.

Enter a product review:

I saw the Director's Cut and thought I would like it too. Well, I did and am glad I did. I am a huge fan of Treme and it is a great movie. It is a good film to watch once. I really enjoy this show. I love it. I love the way it shows the different ways people are different from each other

Analyze

Clear

Result

⚠ This review is classified as **FAKE**.

Prediction

FAKE

Confidence Score

74.9%



Şekil 9: Streamlit arayüzünde 'SAHTE YORUM' sonucu (güven %74,9)

Fake Review Detection System

AI-based review authenticity analysis interface

This model was trained on an English fake review dataset. For reliable results, enter English product reviews.

Enter a product review:

It works alright, though I have had it for a long time. The only reason I give it 4 stars is the design. But it still does the job.

Analyze

Clear

Result

⚠ The model is **UNCERTAIN** for this review.

Raw model prediction: FAKE

Prediction

UNCERTAIN

Confidence Score

55.0%

Şekil 10: Streamlit arayüzünde 'KARARSIZ' sonucu (güven %55,0 – ham tahmin SAHTE olsa da eşik altında olduğu için işaretlenmemiştir)

BÖLÜM 5: TARTIŞMA

5.1 Araştırma Sorularının Cevaplanması

Bu bölümde, Giriş bölümünde anlatılan konulan araştırma soruları deneysel sonuçlar ışığında cevaplanmaktadır.

S1 – TF-IDF ile tespit düzeyi: TF-IDF öznitelikleri kullanılarak sahte yorumlar %86,95 ile %91,29 arasında doğrulukla tespit edilebilmektedir. Bu sonuç, metin tabanlı özniteliklerin sahte yorum tespitinde etkili olduğunu göstermektedir.

S2 – Algoritmalar arası farklılıklar: Evet, algoritmalar arasında belirgin performans farklılıkları mevcuttur. En iyi model (SVM, %91,29) ile en düşük performanslı model (Rastgele Orman, %86,95) arasında yaklaşık 4 puanlık bir fark bulunmaktadır.

S3 – En iyi algoritma: SVM (LinearSVC), hem en yüksek doğruluk oranına (%91,29) hem de en düşük çapraz doğrulama standart sapmasına ($\pm 0,0016$) sahiptir.

S4 – Dış test performansı: Eğitilen modeller Kaggle test seti üzerinde yüksek başarı gösterirken, eğitim veri seti dışında hazırlanan 100 örnekle dış test setinde sahte yorum yakalama oranı belirgin biçimde düşmüştür (Bölüm 4.6.2). Bu durum, klasik makine öğrenmesi modellerinin eğitim veri setindeki dilsel örüntülere bağımlı kaldığını ve farklı kaynaklardan gelen örneklerde genelleme kapasitesinin sınırlı olduğunu göstermektedir.

5.2 Model Performanslarının Değerlendirilmesi

Model performansları karşılaştırıldığında LinearSVC'nin en yüksek iç test başarısını verdiği görülmüştür. Bu sonuç, TF-IDF ile elde edilen yüksek boyutlu ve seyrek metin özniteliklerinin doğrusal sınıflandırıcılarla iyi çalışmasıyla açıklanabilir. Naive Bayes daha hızlı ve basit olmasına rağmen bazı sahte yorumları gerçek olarak sınıflandırmıştır. Rastgele Orman ise metin sınıflandırmadaki yüksek boyutlu seyrek veri yapısında diğer modellere göre daha düşük performans göstermiştir.

SVM'nin en yüksek performansı göstermesi literatürle tutarlıdır (Ott vd., 2011; Joachims, 1998). SVM'nin üstün performansının temel nedenleri şunlardır: (1) yüksek boyutlu uzayda etkinlik — TF-IDF ile oluşturulan 20.000 boyutlu öznitelik uzayında SVM optimal ayırıcı hiper-düzlemi etkili bir şekilde bulabilmektedir; (2) marja dayalı öğrenme — SVM, sınıflar arası en geniş marja odaklanarak genelleme kapasitesini maksimize eder; (3)

seyrek verilere uygunluk — TF-IDF matrisleri son derece seyrek yapıdadır ve SVM bu tür verilerde diğer algoritmalarından daha iyi çalışmaktadır.

Rastgele Orman'ın en düşük performansı göstermesi ise dikkat çekicidir. Bu durumun temel nedeni TF-IDF matrislerinin seyrek yapısıdır: karar ağaçları seyrek verilerde ayırım noktası bulmakta zorlanır çünkü her düğümde yalnızca bir öznitelik üzerinden bölünme yapılır. Ayrıca Rastgele Orman, her ağaç için rastgele bir öznitelik alt kümesi seçer; 20.000 öznitelik içerisinde seçilen küçük alt kümeler en ayırt edici kelimeleri kaçırabilir. Lojistik Regresyon, SVM'ye yakın performans göstererek doğrusal sınıflandırıcıların metin verilerinde güçlü olduğunu doğrulamıştır. Naive Bayes, basit yapısına rağmen %89,08 doğruluk ile makul bir baseline performans sunmuştur.

5.3 Literatür ve Pratik Karşılaştırma

Bu çalışmada Kaggle Fake Reviews Dataset (40.432 yorum) üzerinde SVM modeli %91,29 doğruluğa ulaşmıştır. Veri setleri, üretim biçimleri ve örnek sayıları farklı olduğu için bu sonuç doğrudan üstünlük iddiası olarak değil, TF-IDF + SVM yaklaşımının tutarlı bir baseline oluşturduğunu gösteren bir bulgu olarak değerlendirilmelidir. Mohawesh ve arkadaşlarının (2021) kapsamlı tarama çalışmasında belirtildiği gibi, geleneksel ML yöntemleri sahte yorum tespitinde %85–92 aralığında doğruluk elde etmektedir; bu çalışmanın sonuçları, bu aralığın üst kısmına denk gelmektedir.

BERT tabanlı modeller (Fornaciari vd., 2021; Gupta vd., 2021) %92'nin üzerinde doğruluk elde etmiştir. Ancak bu modeller önemli ölçüde daha fazla hesaplama kaynağı gerektirmektedir. Pratik açıdan değerlendirildiğinde, TF-IDF + SVM kombinasyonu GPU gerektirmeden CPU üzerinde milisaniyeler içinde tahmin yapabilmesi sayesinde yerel ve düşük maliyetli prototipler için uygun bir adaydır. Modelin %91,29 doğruluk oranı, Kaggle test seti üzerinde her 10 yorumdan yaklaşık 9'unu doğru sınıflandırdığını göstermektedir.

5.4 Sınırlılıklar ve Dış Test Bulguları

Bu çalışmanın deneysel sonuçları, sahte yorum tespiti alanında önemli bir durumu gösterir: jeneratör kayması (generator shift). Kullanılan Kaggle Fake Reviews Dataset, 2022 yılında Salminen ve arkadaşları tarafından GPT-2 mimarisi ile üretilmiştir. O dönemden bu yana büyük dil modelleri (GPT-3, GPT-4 ve eşdeğerleri) üretim kalitesinde ilerleme

kaydetmiştir. Bu çalışmadaki dış test deneyleri, eski mimarilerle üretilmiş verilerle eğitilen modellerin modern üretimleri tespit etmekte zorlandığını açıkça göstermiştir.

Bu durumun pratik sonucu şudur: e-ticaret platformlarına entegre edilecek bir sahte yorum tespit sistemi, yalnızca akademik veri setlerindeki performansa dayanmamalı; gerçek dünya senaryolarındaki dağılım kayması da değerlendirilmelidir. Bu bulgu, makine öğrenmesi modellerinin sürekli yeniden eğitilmesi (continual learning) ve çoklu jeneratör verisi ile beslenmesi gerekliliğini desteklemektedir.

Çalışmanın başlıca sınırlılıkları şunlardır: yalnızca metin içeriği kullanılmıştır; kullanıcı davranışı ve platform verileri modele dahil edilmemiştir; kullanılan sahte yorumlar belirli bir veri setindeki CG örnekleriyle sınırlıdır; dış test seti daha küçük ölçekte hazırlanmıştır. Bu sınırlılıklar, modelin gerçek platformlarda doğrudan kullanılmadan önce daha geniş ve çeşitli veriyle test edilmesi gerektiğini göstermektedir.

BÖLÜM 6: SONUÇ VE GELECEK ÇALIŞMALAR

6.1 Sonuç

Bu çalışmada, sahte yorum tespiti için dört farklı makine öğrenmesi algoritması karşılaştırmalı olarak değerlendirilmiştir. 40.432 yorumdan oluşan dengeli bir veri seti üzerinde NLP ön işleme ve TF-IDF öznitelik çıkarımı uygulanmış, Naive Bayes, Lojistik Regresyon, SVM ve Rastgele Orman modelleri eğitilmiştir. Deneysel sonuçlar, SVM tabanlı modelin %91,29 doğruluk oranı ile en yüksek performansı sağladığını göstermektedir. 5-katlı çapraz doğrulama, tüm modellerin genelleme kapasitesini doğrulamıştır.

İç test sonuçlarında LinearSVC modeli en başarılı klasik model olmuştur. Ancak dış test sonuçları, gerçekçi sahte yorumların yakalanmasında modelin sınırlı kaldığını göstermiştir. Bu yüzden de çalışmanın temel çıktısı yalnızca çalışan bir sınıflandırıcı değil, aynı zamanda modelin hangi koşullarda güvenilir, hangi koşullarda sınırlı olduğunun analiz edilmesidir. Arayüzde eklenen 'kararsız' sonucu, düşük güvenli tahminlerin daha temkinli sunulmasını sağlamaktadır.

6.2 Gelecek Çalışmalar

Bu çalışmanın genişletilmesi için aşağıdaki yönler önerilmektedir:

Davranışsal özniteliklerin eklenmesi: Kullanıcı profil bilgileri, yorum zamanlama kalıpları ve sosyal ağ özellikleri modele dahil edilebilir.

Transformer tabanlı modeller: BERT, RoBERTa ve DistilBERT gibi modeller, bağlamsal anlamı daha iyi yakalayabildiği için ileride klasik TF-IDF tabanlı modellerle karşılaştırmalı olarak denenebilir.

Çok dilli destek: Modelin Türkçe, Almanca gibi farklı dillerdeki yorumlara uyarlanması araştırılabilir.

Çoklu jeneratör veri artırımı: Eğitim veri setinin farklı dil modelleri (GPT-4, Claude, Gemini) tarafından üretilmiş örneklerle genişletilmesi modelin jeneratör kaymasına karşı dayanıklılığını artırabilir.

Sürekli öğrenme (continual learning): Yeni dil modelleri ve daha modern, kapsamlı veri setleri ortaya çıktıkça modelin yeniden eğitilmesini sağlayacak sistematik bir pipeline tasarımı, modelin zaman içinde güncel kalmasına katkı sağlayacaktır.

Karma yaklaşımlar: TF-IDF tabanlı yüzeysel metin özellikleri, transformer tabanlı bağlamsal öznitelikler ve kullanıcı davranış sinyalleri birleştirilerek daha dayanıklı sistemler geliştirilebilir.

Dağılım dışı tespit (OOD detection): Modelin tahmin yaparken kendi güveninden emin olmadığı örnekleri tanıyabilmesi için ek bir OOD detektör katmanı entegre edilebilir.

KAYNAKLAR

- Balkus, S. V. ve Yan, D. (2024). Improving short text classification with augmented data using GPT-3. *Natural Language Engineering*, 30(5), 943–972. <https://doi.org/10.1017/S1351324923000414>
- Bird, S., Klein, E. ve Loper, E. (2009). *Natural Language Processing with Python*. O'Reilly Media. <https://www.nltk.org/book/>
- Breiman, L. (2001). Random forests. *Machine Learning*, 45(1), 5–32. <https://doi.org/10.1023/A:1010933404324>
- BrightLocal (2024). Local Consumer Review Survey 2024. <https://www.brightlocal.com/research/local-consumer-review-survey-2024/>
- Dugan, L., Hwang, A., Trhlík, F., Ludan, J. M., Zhu, A., Xu, H., Ippolito, D. ve Callison-Burch, C. (2024). RAID: A shared benchmark for robust evaluation of machine-generated text detectors. *Proceedings of ACL 2024*, 12463–12492. <https://doi.org/10.18653/v1/2024.acl-long.674>
- Feng, S., Banerjee, R. ve Choi, Y. (2012). Syntactic stylometry for deception detection. *Proceedings of the 50th Annual Meeting of the Association for Computational Linguistics*, 171–175. <https://aclanthology.org/P12-2034/>
- Fornaciari, T., Bianchi, F., Poesio, M. ve Hovy, D. (2021). BERTective: Language models and contextual information for deception detection. *Proceedings of EACL 2021*, 2699–2708. <https://doi.org/10.18653/v1/2021.eacl-main.232>
- Gupta, P., Gandhi, S. ve Chakravarthi, B. R. (2021). Leveraging transfer learning techniques — BERT, RoBERTa, ALBERT and DistilBERT for fake review detection. *Proceedings of FIRE 2021*, 75–82. <https://doi.org/10.1145/3503162.3503169>
- Hajek, P., Barushka, A. ve Munk, M. (2020). Fake consumer review detection using deep neural networks integrating word embeddings and emotion mining. *Neural Computing and Applications*, 32(23), 17259–17274. <https://doi.org/10.1007/s00521-020-04757-2>
- Jindal, N. ve Liu, B. (2008). Opinion spam and analysis. *Proceedings of the 2008 International Conference on Web Search and Data Mining (WSDM '08)*, 219–230. <https://doi.org/10.1145/1341531.1341560>
- Joachims, T. (1998). Text categorization with support vector machines: Learning with many relevant features. *Machine Learning: ECML-98, LNCS 1398*, 137–142. <https://doi.org/10.1007/BFb0026683>
- Kohavi, R. (1995). A study of cross-validation and bootstrap for accuracy estimation and model selection. *Proceedings of IJCAI 1995*, 1137–1145. <https://www.ijcai.org/Proceedings/95-2/Papers/016.pdf>
- Liu, R. ve Poesio, M. (2024). Data augmentation for fake reviews detection in multiple languages and multiple domains. *arXiv preprint arXiv:2504.06917*. <https://arxiv.org/abs/2504.06917>
- Luca, M. ve Zervas, G. (2016). Fake it till you make it: Reputation, competition, and Yelp review fraud. *Management Science*, 62(12), 3412–3427. <https://doi.org/10.1287/mnsc.2015.2304>

- Manning, C. D., Raghavan, P. ve Schütze, H. (2008). Introduction to Information Retrieval. Cambridge University Press. <https://nlp.stanford.edu/IR-book/>
- Mexwell (2023). Fake reviews dataset [Veri seti]. Kaggle. <https://www.kaggle.com/datasets/mexwell/fake-reviews-dataset>
- McCallum, A. ve Nigam, K. (1998). A comparison of event models for naive Bayes text classification. AAAI Workshop on Learning for Text Categorization, 41–48. <https://cdn.aaai.org/Workshops/1998/WS-98-05/WS98-05-007.pdf>
- Mohawesh, R., Xu, S., Tran, S. N., Ollington, R., Springer, M., Jararweh, Y. ve Maqsood, S. (2021). Fake reviews detection: A survey. IEEE Access, 9, 65771–65802. <https://doi.org/10.1109/ACCESS.2021.3075573>
- Mukherjee, A., Liu, B. ve Glance, N. (2012). Spotting fake reviewer groups in consumer reviews. Proceedings of WWW 2012, 191–200. <https://doi.org/10.1145/2187836.2187863>
- Mukherjee, A., Kumar, A., Liu, B., Wang, J., Hsu, M., Castellanos, M. ve Ghosh, R. (2013). Spotting opinion spammers using behavioral footprints. Proceedings of KDD 2013, 632–640. <https://doi.org/10.1145/2487575.2487580>
- Ott, M., Choi, Y., Cardie, C. ve Hancock, J. T. (2011). Finding deceptive opinion spam by any stretch of the imagination. Proceedings of ACL-HLT 2011, 309–319. <https://aclanthology.org/P11-1032/>
- Pedregosa, F., Varoquaux, G., Gramfort, A., Michel, V., Thirion, B., Grisel, O., Blondel, M., Prettenhofer, P., Weiss, R., Dubourg, V., Vanderplas, J., Passos, A., Cournapeau, D., Brucher, M., Perrot, M. ve Duchesnay, E. (2011). Scikit-learn: Machine learning in Python. Journal of Machine Learning Research, 12, 2825–2830. <https://jmlr.org/papers/v12/pedregosa11a.html>
- Salminen, J., Kandpal, C., Kamel, A. M., Jung, S. G. ve Jansen, B. J. (2022). Creating and detecting fake reviews of online products. Journal of Retailing and Consumer Services, 64, 102771. <https://doi.org/10.1016/j.jretconser.2021.102771>
- Salton, G. ve Buckley, C. (1988). Term-weighting approaches in automatic text retrieval. Information Processing & Management, 24(5), 513–523. [https://doi.org/10.1016/0306-4573\(88\)90021-0](https://doi.org/10.1016/0306-4573(88)90021-0)
- Vapnik, V. N. (1995). The Nature of Statistical Learning Theory. Springer-Verlag. <https://doi.org/10.1007/978-1-4757-2440-0>